

Yifei Wang

北京理工大学

M 18213820019

E 1120243123@bit.edu.cn

W sophie618.github.io

3441606266@qq.com github.com/Sophie618



教育背景

- 2024.09–至今 计算机科学与技术专业 · 徐特立英才班, 北京理工大学, 工学学士在读
- 徐特立英才班教学班班长;
 - CET-4: 572; 全国大学生英语竞赛二等奖。

研究兴趣

- 自适应智能体 强化学习与长期记忆、长程交互中的学习和决策
- 模型自进化 递归学习、反馈驱动的自我改进与能力演化
- 多模态智能 多模态基础模型、智能体系统、模型可解释性及脑—模型语义对齐

科研经历

- 2025.12– 2026.05 **Threader: 面向对话智能体的长期记忆**, 清华大学科研合作, 共同作者, 2026 NeurIPS 在投
- 针对传统对话智能体压缩式记忆存在的信息丢失、高延迟和高成本问题, 设计并实现无损长效记忆框架 Threader。
 - 提出“主题分割+多视角编码+多信号检索”范式, 摒弃依赖大语言模型的摘要压缩流程; 在对话记忆任务中实现 100% 信息保留, 构建速度提升一个数量级, 并大幅降低 Token 成本。
 - 在多个长对话记忆基准上全面超越 MemGPT、Mem0 等主流 SOTA 模型, 显著提升智能体的长程对话一致性与响应效率。
- 2025.09– 2026.05 **SAIL: 脑—模型语义对齐**, 北京理工大学, 共同作者, 2026 NeurIPS 在投
- 针对多模态大模型 (MLLM) 内部表征纠缠、可解释性差的问题, 构建基于稀疏自编码器 (SAE) 的脑—模型语义对齐框架 SAIL。
 - 通过 SAE 将高维视觉特征解纠缠为单语义概念原子, 并与人类视觉皮层 fMRI 信号精准匹配, 揭示 MLLM 与腹侧视觉通路的层级对应关系。
 - 实验表明, SAE 提取的特征相较原始模型特征, 在人脑对齐任务上的性能提升显著, 为多模态模型可解释性研究提供了新的范式。

实习经历

- 2026.04– 2026.06 **产品解决方案实习生**, 字节跳动 · 火山方舟, 北京, AI 产品与 MaaS 解决方案
- 参与企业级 AI 产品与 MaaS 解决方案设计, 梳理基础模型能力、业务场景与产品落地路径。
 - 支持 ToB AI 场景的解决方案调研与产品沟通, 将技术能力转化为可执行的业务方案。

项目经历

- 2026.01 **Collector+ (Collector-AI): 基于线性单体架构的低延迟信息提取助手**, *GitHub*; 在线演示
- 通过大语言模型将长文本或视频快速转化为二元预测性问题, 实现“游戏化阅读”(Gamified Reading)。
 - 摒弃复杂的 Agent 编排, 设计 Linear Monolithic 线性单体架构并结合 FastAPI 异步处理, 将端到端生成延迟压缩至 15–30 秒。
 - 设计认知科学家 System Prompt, 在单次推理中通过 Chain-of-Thought 完成内容重构、反直觉观点挖掘与格式化输出。
 - 实现微信公众号、哔哩哔哩通用内容解析器, 以及动态渲染页面的通用解析, 解决懒加载和动态渲染问题; 使用 React Context 管理全局状态, 构建直觉对赌交互机制。
- 2025.12 **BitSnap: 基于视频语义理解的结构化指令生成系统**, 在线演示, 私有仓库, 可提供技术报告
- 面向人类学习场景中非结构化视频难以被执行的问题, 构建将长视频实时转化为结构化步骤指令的系统。
 - 使用 Python 抓取哔哩哔哩视频字幕与元数据, 构建“视频—文本—指令”映射管道; 利用 DeepSeek-V3 进行长文本语义理解, 开发内容无关的提取算法, 自动过滤冗余信息并归纳核心操作。
 - 通过 System Prompt 约束模型输出严格 JSON 格式, 包含时间戳、操作分类和关键参数, 实现从流式媒体到结构化指令的跨维度转换。
 - 使用 Next.js 16、React 19 和 Zustand 构建前端, 完成视频时间戳与步骤卡片的双向实时联动, 并按健身、烹饪等任务动态生成领域界面。
- 2024.09–2025.10 **BIGEM 数据检索与可视化平台**, *GitLab* 源码, 项目 Wiki
- 获 2025 iGEM 国际金奖及全球本科生组 Best Software 奖, 并正向上申报软件著作权。
 - 面向 2004–2024 年合成生物学竞赛数据, 使用 Python 爬虫完成海量科研数据清洗; 基于 D3.js 和 Three.js 实现力导向图、桑基图和树状关系图的动态渲染, 揭示全球队伍间的合作网络。
 - 接入大模型 API, 对生物元件库进行语义分析, 实现超越关键词匹配的模糊扩展搜索, 提升科研数据检索效率。
- 2025.11–至今 **Multi-Agent: 基于 MCP 协议的电商智能助手平台**, *GitHub*, 重构中
- 探索 Anthropic 发布的模型上下文协议 (MCP), 构建连接大语言模型与 Medusa 电商后台的智能中介系统。
 - 搭建标准 MCP Server, 使大语言模型通过通用协议自动发现并调用 `search_products`、`get_details` 等工具。
 - 探索 Planner-Worker 多智能体协作架构, 并结合 RAG 增强任务处理。
 - 实现“用户请求 → Claude 大语言模型 → 路由器 → MCP Server → 后端 API”的完整数据链路, 验证大语言模型操作外部系统的可行性。
 - 使用 Vue 3 构建对话界面, 解析工具执行结果并渲染为可视化商品卡片; 项目正由单 Agent 向 Multi-Agent 架构演进。

专业技能

- 编程学习 Python、PyTorch、TypeScript
- 开发技能 React、Git
- 语言能力 中文 (母语); 英语 (流利)

荣誉与奖项

- 2025 iGEM 国际遗传工程机器设计竞赛国际金奖; 全球本科生组 Best Software 奖
- 2025 全国大学生数学建模竞赛北京市一等奖
- 2025 全国大学生英语竞赛二等奖
- 2026 美国大学生数学建模竞赛 H 奖